

Hadoop快速入门

目录

| | |
|------------------------|---|
| 1 目的..... | 2 |
| 2 先决条件..... | 2 |
| 2.1 支持平台..... | 2 |
| 2.2 所需软件..... | 2 |
| 2.3 安装软件..... | 2 |
| 3 下载..... | 3 |
| 4 运行Hadoop集群的准备工作..... | 3 |
| 5 单机模式的操作方法..... | 3 |
| 6 伪分布式模式的操作方法..... | 3 |
| 6.1 配置..... | 3 |
| 6.2 免密码ssh设置..... | 4 |
| 6.3 执行..... | 4 |
| 7 完全分布式模式的操作方法..... | 5 |

1. 目的

这篇文档的目的是帮助你快速完成单机上的Hadoop安装与使用以便你对[Hadoop分布式文件系统\(HDFS\)](#)和Map-Reduce框架有所体会，比如在HDFS上运行示例程序或简单作业等。

2. 先决条件

2.1. 支持平台

- GNU/Linux是产品开发和运行的平台。Hadoop已在有2000个节点的GNU/Linux主机组成的集群系统上得到验证。
- Win32平台是作为开发平台支持的。由于分布式操作尚未在Win32平台上充分测试，所以还不作为一个生产平台被支持。

2.2. 所需软件

Linux和Windows所需软件包括：

1. JavaTM1.5.x，必须安装，建议选择Sun公司发行的Java版本。
2. ssh 必须安装并且保证 sshd一直运行，以便用Hadoop 脚本管理远端Hadoop守护进程。

Windows下的附加软件需求

1. [Cygwin](#) - 提供上述软件之外的shell支持。

2.3. 安装软件

如果你的集群尚未安装所需软件，你得首先安装它们。

以Ubuntu Linux为例：

```
$ sudo apt-get install ssh
$ sudo apt-get install rsync
```

在Windows平台上，如果安装cygwin时未安装全部所需软件，则需启动cyqwin安装管理器安装如下软件包：

- openssh - Net 类

3. 下载

为了获取Hadoop的发行版，从Apache的某个镜像服务器上下载最近的 [稳定发行版](#)。

4. 运行Hadoop集群的准备工作

解压所下载的Hadoop发行版。编辑 `conf/hadoop-env.sh` 文件，至少需要将 `JAVA_HOME` 设置为Java安装根路径。

尝试如下命令：

```
$ bin/hadoop
```

将会显示hadoop 脚本的使用文档。

现在你可以用以下三种支持的模式中的一种启动Hadoop集群：

- 单机模式
- 伪分布式模式
- 完全分布式模式

5. 单机模式的操作方法

默认情况下，Hadoop被配置成以非分布式模式运行的一个独立Java进程。这对调试非常有帮助。

下面的实例将已解压的 `conf` 目录拷贝作为输入，查找并显示匹配给定正则表达式的条目。输出写入到指定的output目录。

```
$ mkdir input
```

```
$ cp conf/*.xml input
```

```
$ bin/hadoop jar hadoop-*-examples.jar grep input output 'dfs[a-z.]+'
```

```
$ cat output/*
```

6. 伪分布式模式的操作方法

Hadoop可以在单节点上以所谓的伪分布式模式运行，此时每一个Hadoop守护进程都作为一个独立的Java进程运行。

6.1. 配置

使用如下的 `conf/hadoop-site.xml`:

| |
|--|
| <code><configuration></code> |
| <code><property></code> |
| <code><name>fs.default.name</name></code> |
| <code><value>localhost:9000</value></code> |
| <code></property></code> |
| <code><property></code> |
| <code><name>mapred.job.tracker</name></code> |
| <code><value>localhost:9001</value></code> |
| <code></property></code> |
| <code><property></code> |
| <code><name>dfs.replication</name></code> |
| <code><value>1</value></code> |
| <code></property></code> |
| <code></configuration></code> |

6.2. 免密码ssh设置

现在确认能否不输入口令就用ssh登录localhost:

```
$ ssh localhost
```

如果不输入口令就无法用ssh登陆localhost, 执行下面的命令:

```
$ ssh-keygen -t dsa -P '' -f ~/.ssh/id_dsa
```

```
$ cat ~/.ssh/id_dsa.pub >> ~/.ssh/authorized_keys
```

6.3. 执行

格式化一个新的分布式文件系统:

```
$ bin/hadoop namenode -format
```

启动Hadoop守护进程:

```
$ bin/start-all.sh
```

Hadoop守护进程的日志写入到 `${HADOOP_LOG_DIR}` 目录（默认是 `${HADOOP_HOME}/logs`）。

浏览NameNode和JobTracker的网络接口，它们的地址默认为：

- NameNode - <http://localhost:50070/>
- JobTracker - <http://localhost:50030/>

将输入文件拷贝到分布式文件系统：

```
$ bin/hadoop fs -put conf input
```

运行发行版提供的示例程序：

```
$ bin/hadoop jar hadoop-*-examples.jar grep input output 'dfs[a-z.]+'
```

查看输出文件：

将输出文件从分布式文件系统拷贝到本地文件系统查看：

```
$ bin/hadoop fs -get output output
```

```
$ cat output/
```

或者

在分布式文件系统上查看输出文件：

```
$ bin/hadoop fs -cat output/
```

完成全部操作后，停止守护进程：

```
$ bin/stop-all.sh
```

7. 完全分布式模式的操作方法

关于搭建完全分布式模式的，有实际意义的集群的资料可以在[这里](#)找到。

Java与JNI是Sun Microsystems, Inc.在美国以及其他国家地区的商标或注册商标。